ANÁLISIS Y MIGRACIÓN DE LA BASE DE DATOS JARDINERÍA

Construcción de la Base de Datos Staging

Actividad practica # 2

Nombre: Kevin Andrés Valencia Daza

Curso: Bases de Datos 2
PREICA2601B010048

Docente: Antonio Jesús Valderrama

Institución Universitaria Digital de Antioquia
Medellín, Colombia
2026

Tabla de Contenido

1. Introducción 3
2. Objetivos 4
2.1 Objetivo General 4
2.2 Objetivos Específicos 4
3. Planteamiento del Problema 5
4. Análisis del Problema 6
4.1 Estructura de la Base de Datos Jardinería 6
4.2 Identificación de Datos Relevantes y No Relevantes 6
5. Propuesta de Solución 8
5.1 Diseño de la Base de Datos Staging 8
5.1.1 Modelo Dimensional (Star Schema) 8
5.1.2 Transformaciones Aplicadas 8
5.2 Implementación en Google Colab 9
5.2.1 Entorno de Trabajo 9
5.2.2 Proceso de Migración 10
5.2.3 Estrategia de Migración SQL 10
5.3 Validaciones Realizadas 11
6. Conclusiones 12
7. Anexos 13
Anexo A — Backup de la base de datos Jardinería 13
Anexo B — Backup de la base de datos Staging 13
Anexo C — Script SQL de creación de la base Staging 13
Anexo D — Notebook de Google Colab 14
8. Bibliografía 15

1. Introducción

En la actualidad, las empresas tienen un gran descubrimiento: convertir los datos que tienen dispersos en información hasta que esté de entender. La base de datos Jardinería es un ejemplo de un sistema que maneja todos los datos de una empresa de jardinería y venta de plantas. Esto incluye información sobre las oficinas, los empleados, los clientes, los productos, los pedidos y los pagos.

Este documento explica cómo se creó una base de datos llamada Staging a partir de la base de datos Jardinería. La base de datos Staging es como un puente entre los sistemas que generan datos y los sistemas que los analizan. Recibe los datos, los limpia, los transforma y los organiza para que se puedan cargar en un almacén de datos o utilizar en análisis.

El proyecto se realizó en un entretenimiento llamado Google Colab, utilizando SQLite como base de datos. Esto permitió hacer todo el proceso de extracción, transformación y carga de datos sin necesidad de más infraestructura. Los resultados son la estructura de la base de datos Staging, los scripts para migrar los datos y las copias de seguridad de ambas bases de datos.

2. Objetivos

2.1 Objetivo General

Analizar la base de datos Jardinería, identificar los datos relevantes para procesos analíticos y construir una base de datos Staging, mediante scripts SQL ejecutados en un entorno Google Colab con SQLite.

2.2 Objetivos Específicos

- Revisar la estructura y los datos de la base de datos Jardinería para determinar su relevancia analítica.
- Diseñar el modelo dimensional de la base de datos Staging, definiendo tablas de dimensiones y tablas de hechos.
- Construir los scripts SQL de creación de tablas e inserción de datos para la base de datos Staging.
- Validar la integridad y completitud de los datos migrados mediante consultas de verificación.
- Generar los archivos de backup de ambas bases de datos y documentar el proceso.

3. Planteamiento del Problema

La base de datos Jardinería se creó para manejar operaciones cotidianas de manera eficiente. Esto significa que está diseñada para registrar pedidos, gestionar pagos, actualizar el stock de productos y mantener la información de los clientes y empleados. Sin embargo, este tipo de diseño tiene limitaciones importantes cuando necesita analizar la información de la empresa. Algunos de los problemas que se presentan:

* La existencia de columnas con información que no está organizada, como descripciones en texto libre, que no son útiles para el análisis.

* La presencia de datos de contacto que no son necesarios o que no aportan mucho valor, como el fax o la dirección completa de un empleado.

* La complejidad de las relaciones entre las tablas, lo que hace difícil crear consultas para analizar la información.

* La falta de métricas que ya están calculadas, como el valor total de cada línea de pedido.

Todos estos problemas tienen necesidad de crear una base de datos Staging. Esta base de datos debe centralizar solo la información relevante para el análisis, limpiar los datos, organizar de manera parcial y estructurarlos para que sea fácil generar informes e indicadores de negociación. Este es el primer paso antes de utilizar un Data Warehouse o una herramienta de Business Intelligence.

4. Análisis del Problema

4.1 Estructura de la Base de Datos Jardinería

La base de datos Jardinería está compuesta por ocho (8) tablas relacionales que modelan el negocio de comercialización de productos de jardinería. La siguiente tabla resume su estructura:

Tabla	Registros aprox.	Tipo	Descripción
Oficina	9	Catálogo	Oficinas de la empresa a nivel global
Empleado	31	Catálogo	Personal con jerarquía y asignación por oficina
Categoria_producto	5	Catálogo	Clasificación de productos por tipo
Cliente	36	Maestro	Clientes con contacto, dirección y crédito
Producto	276+	Maestro	Productos con precio, stock y proveedor
Pedido	115+	Transaccional	Cabecera de pedidos con estado y fechas
detalle_pedido	~300+	Transaccional	Líneas de pedido con cantidad y precio
Pago	26	Transaccional	Pagos de clientes con forma y monto

4.2 Identificación de Datos Relevantes y No Relevantes

Para determinar qué datos debían trasladarse a la base Staging, se aplicaron los siguientes criterios de análisis:

- Relevancia analítica: el dato debe permitir calcular métricas de negocio (ventas, ingresos, pagos, rotación de inventario).

- Estructuración: el dato debe estar en formato estructurado y no en texto libre extenso.
- No redundancia: se eliminaron campos duplicados o derivables de otros (por ejemplo, fax es redundante con teléfono).
- Granularidad: se priorizaron campos que permiten segmentación por dimensiones (país, ciudad, categoría, empleado).

Tabla origen	Campo excluido	Razón de exclusión	Destino Staging
oficina	linea_direccion1, linea_direccion2	Dato operativo, no analítico	dim_oficina
empleado	extension	Dato interno de PBX	dim_empleado
cliente	fax, linea_direccion*, codigo_postal	Datos de contacto, no BI	dim_cliente
Categoria_producto	descripcion_texto, descripcion_html, imagen	Contenido web, no estructurado	dim_categoria
producto	dimensiones, descripcion	Texto libre, no analítico	dim_producto
pedido + detalle_pedido	comentarios	Texto libre sin valor BI	fact_pedidos
pago	—	Todos los campos son relevantes	fact_pagos

5. Propuesta de Solución

5.1 Diseño de la Base de Datos Staging

5.1.1 Modelo Dimensional (Star Schema)

La base de datos Staging fue diseñada bajo el modelo estrella (star schema), ampliamente utilizado en soluciones de Business Intelligence. Este modelo organiza los datos alrededor de una o varias tablas de hechos (facts) que contienen las métricas del negocio, rodeadas por tablas de dimensiones (dimensions) que proveen el contexto descriptivo para el análisis.

La base Staging resultante contiene siete (7) tablas: cinco (5) dimensiones y dos (2) tablas de hechos, según se detalla a continuación:

Tabla Staging	Tipo	Descripción
dim_oficina	Dimensión	Ubicación geográfica y contacto de oficinas
dim_empleado	Dimensión	Personal con nombre completo concatenado y cargo
dim_cliente	Dimensión	Clientes con datos de segmentación geográfica y crédito
dim_categoria	Dimensión	Clasificación de productos por familia
dim_producto	Dimensión	Productos con precio y proveedor para análisis de margen
fact_pedidos	Tabla de hechos	Líneas de pedido con cantidad, precio y total calculado. Combina pedido y detalle_pedido
fact_pagos	Tabla de hechos	Transacciones de pago por cliente con forma y monto

5.1.2 Transformaciones Aplicadas

Durante la migración de Jardinería a Staging se aplicaron las siguientes transformaciones sobre los datos:

- Concatenación de nombres: los campos nombre, apellido1 y apellido2 de la tabla empleado se unificaron en un solo campo nombre_completo mediante la función TRIM y concatenación condicional, mejorando la legibilidad analítica.
- Unificación de tablas de hechos: las tablas pedido y detalle_pedido fueron combinadas en una sola tabla de hechos fact_pedidos mediante un JOIN, reduciendo la complejidad de las consultas analíticas y centralizando la información transaccional de ventas.
- Campo calculado total_linea: se agregó la columna total_linea = cantidad × precio_unidad como campo derivado persistido, eliminando la necesidad de recalcularlo en cada consulta analítica.
- Depuración de campos: se eliminaron 12 campos de baja relevancia analítica identificados en el proceso de análisis (sección 4.2), reduciendo el volumen de datos innecesario en el entorno de análisis.

5.2 Implementación en Google Colab

5.2.1 Entorno de Trabajo

El proyecto fue implementado en Google Colaboratory (Colab), lo que eliminó la necesidad de instalar software adicional. La elección de SQLite como motor de base de datos se justifica por su portabilidad, su compatibilidad con entornos de desarrollo educativos y su sintaxis SQL estándar, compatible con motores empresariales como SQL Server, MySQL o PostgreSQL.

5.2.2 Proceso de Migración

El proceso de migración se implementó en un notebook de Google Colab organizado en diez (10) celdas secuenciales, cada una con una responsabilidad específica dentro del flujo ETL:

Celda	Etapa ETL	Descripción
1	Configuración	Importación de librerías y definición de funciones auxiliares
2	Extracción (E)	Creación del esquema de la base Jardinería (DDL)
3-4	Extracción (E)	Carga de todos los datos en Jardinería (INSERT)
5	Validación	Verificación de conteos por tabla en Jardinería
6	Transformación (T)	Creación del esquema Staging (DDL star schema)
7	Carga (L)	Migración con ATTACH DATABASE + INSERT INTO ... SELECT
8	Validación	5 consultas analíticas de verificación
9	Exportación	Generación de BK (.db) y script SQL de Staging
10	Descarga	Descarga de archivos al computador local

5.2.3 Estrategia de Migración SQL

La migración de datos se realizó utilizando la instrucción ATTACH DATABASE de SQLite, que permite acceder a dos bases de datos simultáneamente en la misma sesión. Esto facilita la ejecución directa de instrucciones INSERT INTO ... SELECT FROM sin necesidad de exportar ni importar archivos intermedios. A continuación se ilustra la consulta de migración de la tabla de hechos de pedidos, que constituye el caso más complejo por involucrar un JOIN entre dos tablas fuente:

```
INSERT INTO fact_pedidos   SELECT dp.ID_detalle_pedido, dp.ID_pedido,
p.fecha_pedido, p.fecha_entrega, p.estado, p.ID_cliente,
dp.ID_producto, dp.cantidad, dp.precio_unidad,     ROUND(dp.cantidad *
dp.precio_unidad, 2),     dp.numero_linea   FROM jard.detalle_pedido dp
JOIN jard.pedido p ON dp.ID_pedido = p.ID_pedido;
```

5.4 Validaciones Realizadas

Se ejecutaron cinco (5) consultas de validación para verificar la integridad y completitud de los datos migrados a la base Staging:

- Conteo de filas por tabla: verificación de que el número de registros en Staging coincida con el número esperado según los datos de Jardinería.
- Ventas totales por categoría: análisis del número de pedidos, unidades vendidas e ingresos agrupados por categoría de producto.
- Top 5 clientes por volumen de pagos: identificación de los clientes con mayor facturación acumulada.
- Distribución de pedidos por estado: conteo de pedidos clasificados por Entregado, Pendiente, Rechazado.
- Formas de pago utilizadas: análisis del número de transacciones y montos totales por método de pago.

Todos los resultados de validación mostraron coherencia con los datos de origen, confirmando que la migración fue exitosa y que los campos calculados (total_linea) presentan valores correctos.

6. Conclusiones

El proceso de análisis y migración de la base de datos Jardinería a la base Staging permitió evidenciar la importancia de diferenciar entre bases de datos operacionales (OLTP) y analíticas (OLAP). Mientras que Jardinería optimiza el registro de transacciones, la base Staging facilita el análisis multidimensional al estructurar los datos en un modelo estrella con dimensiones y tablas de hechos claras.

La implementación en Google Colab demostró que es posible ejecutar un flujo ETL completo utilizando herramientas accesibles y de código abierto. La utilización de ATTACH DATABASE en SQLite es una técnica eficiente para realizar migraciones entre bases de datos en el mismo entorno, evitando la exportación de archivos intermedios.

La depuración de campos no analíticos (12 columnas eliminadas) y la incorporación del campo calculado total_linea mejoran significativamente la calidad y usabilidad del dato en Staging, reduciendo la complejidad de las consultas analíticas y el tiempo de respuesta para la generación de reportes.

7. Anexos

Anexo A — Backup de la base de datos Jardinería

Archivo: BK_jardineria.db

Contenido: Esquema completo + datos de 8 tablas (oficina, empleado, Categoria_producto, cliente, pedido, producto, detalle_pedido, pago).

BK_jardineria..db

Anexo B — Backup de la base de datos Staging

Archivo: BK_staging.db

Contenido: Esquema star schema + datos migrados de 7 tablas (dim_oficina, dim_empleado, dim_cliente, dim_categoria, dim_producto, fact_pedidos, fact_pagos).

BK_staging.db

Anexo C — Script SQL de creación de la base Staging

Archivo: Anexo_Script_Staging.sql

Contenido: DDL (CREATE TABLE) para las 7 tablas de Staging + DML (INSERT INTO ... SELECT) para la migración desde Jardinería.

Anexo_Script_Staging.sql

Anexo D — Notebook de Google Colab

Archivo: Jardineria_Staging_Colab.ipynb

Descripción: Notebook con 10 celdas que implementa el flujo ETL completo desde la creación de Jardinería hasta la exportación de backups y scripts.

Jardineria_Staging_Colab..ipynb

8. Bibliografía

Google LLC. (2024). Google Colaboratory: Frequently asked questions. https://research.google.com/colaboratory/faq.html

Microsoft Corporation. (2024). What is a staging database? SQL Server documentation. https://docs.microsoft.com/en-us/sql/integration-services/

López Montalbán, I. (2007). *Bases de datos.* Script SQL Jardinería. Recuperado de https://gist.github.com/josejuansanchez/c408725e848afd64dd9a20ab37fba8c9